

Centro de Apredizaje de Matemáticas

Universidad de las Américas Puebla

31 de marzo de 2026

Resumen

Este documento evalúa la asociación entre el uso del Centro de Aprendizaje de Matemáticas (CMAT) y el desempeño académico usando calificaciones estandarizadas (Z-score) e imputación de valores faltantes por Kernel Density Estimation (KDE).

El flujo incluye:

1. exploración de la distribución de visitas,
2. diagnóstico de valores faltantes y comparación de estrategias de imputación,
3. evidencia visual de heterogeneidad entre docentes y su relación con la comparabilidad de calificaciones,
4. análisis por aula (agregado) y por estudiante (individual) con pruebas paramétricas (Welch t) y no paramétricas (Mann–Whitney, Brunner–Munzel), tamaños de efecto e intervalos de confianza,
5. una visualización agregada de Z promedio contra visitas con IC95 %.

Índice

1	Panorama general	3
1.1	Pregunta y alcance	3
1.2	Definición operativa de “aula” (unidad de comparación)	3
1.3	Estructura del conjunto de datos y limpieza	3
1.4	Estandarización: ¿por qué? y ¿cómo?	3
1.5	Criterio de agrupamiento por visitas (umbral 3)	4
2	¿Qué es CMAT?	5
3	Análisis exploratorio de datos	6
3.1	¿Cuántas visitas hacen los estudiantes?	6
4	¿Mejoran su desempeño?	7
4.1	¿Cómo se mide el desempeño de forma comparable?	7
4.2	¿Con qué lo comparamos?	7
5	Calificaciones	8
5.1	¿Qué significa “sin calificación”?	8
5.2	Imputación de valores faltantes: comparación visual	8
5.3	Casos especiales: distribución atípica y rangos truncados	9
5.4	Estandarización de imputación	9
5.5	Heterogeneidad entre profesores	9
5.6	Agrupamiento y distancias entre profesores	11
5.7	Distribuciones por profesor: escenarios comparables	12
6	¿Cuál es la mejor forma de estandarizar?	15
7	Análisis por aula (agregado por salón)	16
7.1	Relación visitas–Z-score (dispersión)	16
7.2	Diferencia de medias (prueba t de Welch)	16
7.3	Pruebas robustas y tamaños de efecto	17
8	Análisis por estudiante (individual)	18
8.1	Relación visitas–Z-score (dispersión)	18
8.2	Diferencia de medias (Welch t)	18
8.3	Pruebas robustas, tamaños de efecto e IC95 %	19
9	Gráfica de desempeño	20
9.1	Agregación de Z promedio por visitas con IC95 %	20
10	Conclusiones	21
10.1	Síntesis interpretativa	21
10.2	Alcances y límites	21

1 Panorama general

1.1 Pregunta y alcance

La pregunta central es observacional: si se agrupan estudiantes por su cantidad de visitas al CMAT, ¿aparecen diferencias sistemáticas en desempeño académico medido con una escala comparable? La intención no es atribuir causalidad de forma automática, sino documentar patrones y cuantificarlos con herramientas estadísticas que respeten la estructura de los datos (docente, calificación materia y periodo).

1.2 Definición operativa de “aula” (unidad de comparación)

Para este análisis, se considera un “aula” como **un profesor impartiendo una materia en el mismo periodo, independientemente de si un profesor imparte más de una sección**. Se hace de esta forma porque algunos profesores han cambiado su forma de evaluar durante el tiempo; por ello, el periodo es parte explícita de la unidad de comparación.

Bajo esta definición, dos secciones de la misma materia con el mismo profesor en el mismo periodo se tratan como una sola unidad de evaluación, un mismo “marco de calificación”. En cambio, si el mismo profesor imparte la misma materia en periodos distintos, se consideran aulas distintas, precisamente para capturar cambios intertemporales en nivel promedio, dispersión o forma de la distribución de calificaciones.

1.3 Estructura del conjunto de datos y limpieza

El conjunto analítico se construye de forma que no existan ambigüedades en la unidad de observación:

- **No hay alumnos repetidos en una misma aula:** para cada par aula-estudiante se conserva un único registro, evitando duplicidades dentro de la misma unidad docente-materia-periodo.
- **Se eliminaron registros de alumnos con doble licenciatura,** para reducir mezcla de trayectorias curriculares y posibles esquemas de evaluación-avance que no sean comparables con el resto de manera temporal.
- **Se mantienen las calificaciones de alumnos que reprobaron, bajas voluntarias o retiros temporales:** no se excluyen reprobados, ya que eliminarlos induciría un sesgo de supervivencia y distorsionaría tanto promedios como colas de la distribución.

Estas decisiones buscan que las distribuciones por aula reflejen el comportamiento real del sistema, incluyendo casos de bajo desempeño.

1.4 Estandarización: ¿por qué? y ¿cómo?

El problema práctico es la comparabilidad: distintos docentes o el mismo docente en periodos distintos pueden asignar calificaciones con diferente nivel de exigencia. Por ello se trabaja con calificación estandarizada dentro de cada aula.

Sea g la calificación cruda y sea a una aula. Se define el Z-score:

$$z = \frac{g - \mu_a}{\sigma_a},$$

donde μ_a y σ_a son la media y desviación estándar del aula a bajo el tratamiento de imputación faltantes elegido, como KDE. Esta transformación permite que $z > 0$ signifique “por arriba del promedio de su aula” y $z < 0$ “por debajo”, manteniendo la comparación en una escala común incluso si las calificaciones crudas no son directamente comparables entre aulas.

1.5 Criterio de agrupamiento por visitas (umbral 3)

El análisis usa un corte operativo de 3 visitas para definir grupos: “más de 3” versus “3 o menos”. Además de ser un umbral natural en la distribución, con fuerte concentración en pocas visitas, tiene una interpretación institucional: **con 3 visitas al CMAT se otorgan puntos de PPA1 en algunos periodos**, un requerimiento de la universidad orientado a estudiantes de nuevo ingreso. Esto implica que 3 o menos visitas puede capturar un comportamiento de cumplimiento mínimo para obtener puntos, mientras que más de 3 visitas refleja uso adicional más allá del incentivo mínimo.

2 ¿Qué es CMAT?

El CMAT es un espacio de asesorías académicas al que los estudiantes asisten para reforzar temas y resolver dudas. En este trabajo se usa el número de visitas como medida de exposición al servicio, con la idea de contrastar desempeño relativo entre grupos definidos por visita. La evidencia que se presenta es asociacional: describe diferencias entre grupos y su magnitud con incertidumbre, pero por sí sola no establece que el CMAT sea la causa directa del cambio en calificaciones.

3 Análisis exploratorio de datos

Las Figuras 3.1.1 y 3.1.2 muestran la distribución del número de visitas por estudiante. Aquí se define el contexto básico: cuánto se usa el CMAT, qué tan frecuente es el uso intensivo y cuál es el comportamiento en la cola de visitas altas. Esta inspección es relevante porque, cuando una variable es muy asimétrica, es decir mucha masa cerca de 0 y cola larga, promedios simples pueden ocultar la estructura y las comparaciones deben interpretarse considerando el desbalance entre grupos.

3.1 ¿Cuántas visitas hacen los estudiantes?

En Figura 3.1.1 el histograma concentra la mayor parte de observaciones en valores bajos (incluyendo 0) y presenta una cola larga que llega aproximadamente a 120 visitas. La lectura inmediata es que el uso frecuente del CMAT existe, pero es minoritario frente al uso bajo o nulo. En términos estadísticos, esta forma sugiere asimetría fuerte y presencia de valores extremos; por ello, el análisis posterior evita resumir todo con una sola media de visitas y usa una partición por umbral que separa un grupo de uso relativamente frecuente.




Figura 3.1.1: Histograma del número de visitas al CMAT por estudiante.

En Figura 3.1.2 se presenta la misma distribución, pero distinguiendo dos grupos: “Más de 3 visitas” (9.95 %) y “3 o menos visitas” (90.05 %). Ese corte tiene doble utilidad: (i) separa el uso adicional (más allá de un mínimo) y (ii) refleja una condición institucional, ya que con 3 visitas se obtienen puntos de PPA1 para estudiantes de nuevo ingreso. La consecuencia práctica es un desbalance notable de tamaños muestrales; por ello, más adelante se reportan tamaños de efecto e intervalos de confianza además de p -valores.




Figura 3.1.2: Histograma del número de visitas al CMAT con partición por umbral de 3 visitas (más de 3 vs 3 o menos).

4 ¿Mejoran su desempeño?

A partir del umbral mostrado en Figura 3.1.2, se comparan distribuciones de desempeño entre grupos. Conceptualmente, > 3 visitas busca capturar un patrón de uso que no se reduce al incentivo mínimo (PPA1), mientras que ≤ 3 incluye a quienes no usan el servicio o lo usan de manera limitada (incluyendo quienes podrían haber ido exactamente tres veces para obtener puntos). Esta distinción reduce ambigüedad interpretativa: una diferencia a favor del grupo > 3 visitas se alinea con uso adicional, no solo con cumplimiento del mínimo.

4.1 ¿Cómo se mide el desempeño de forma comparable?

Antes de comparar grupos por visitas, se resuelven dos obstáculos que afectan comparabilidad:

- **Valores faltantes** (“sin calificación”): se decide si se eliminan o se imputan, y se documenta cómo cambia la distribución bajo cada opción.
- **Heterogeneidad docente y temporal**: se estandariza por aula (docente–materia–periodo) para controlar diferencias en severidad y cambios en el tiempo.

Este orden es importante: comparar calificaciones crudas sin controlar por aula puede confundir diferencias de evaluación con diferencias reales de desempeño relativo.

4.2 ¿Con qué lo comparamos?

Sup: Con sus calificaciones, pero utilizando una escala estandarizada por aula (Z-score) y una estrategia explícita para tratar la ausencia de calificación.

5 Calificaciones

5.1 ¿Qué significa “sin calificación”?

En este conjunto de datos, “sin calificación” corresponde a que el estudiante **dio de baja la materia**. Los alumnos tienen la oportunidad de dar de baja antes de cierto periodo; al hacerlo, **no reciben calificación final** en esa materia. Esto es importante porque este tipo de ausencia suele concentrarse en situaciones específicas (por ejemplo, cambios de carga, decisiones estratégicas o anticipación de un resultado desfavorable), por lo que no debe asumirse como un faltante aleatorio sin más.

5.2 Imputación de valores faltantes: comparación visual

En Figura 5.2.1 se comparan tres tratamientos:

- **Eliminada:** se descartan registros sin calificación (bajas).
- **Media:** se imputan faltantes con el promedio del salón.
- **KDE:** se imputan faltantes usando una estimación de densidad.

La lectura es directa: las tres curvas representan cómo se vería la distribución de calificaciones bajo cada decisión. Un punto crítico es que imputar con un valor fijo o altamente concentrado (por ejemplo, imputar alrededor de 7.5) puede introducir **picos artificiales** que no existían en los datos observados, alterando la forma de la distribución y sesgando comparaciones posteriores. Por ello se usa KDE: su objetivo es **preservar la forma global** de la distribución (modos, colas y asimetrías) sin crear masa puntual nueva.

Formalmente, si $x_1, \dots, x_n$ son observaciones (calificaciones) y K es un kernel, entonces

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

donde $h > 0$ es el ancho de banda; en la práctica, h controla el suavizado y, por tanto, qué tan sensible queda la densidad a picos locales. En este contexto, KDE se usa como estrategia para imputar sin “apilar” valores en un punto, evitando cambios estructurales fuertes en la distribución.




Figura 5.2.1: Comparación de métodos de imputación de calificaciones para un salón: eliminación, imputación por media e imputación por KDE.

5.3 Casos especiales: distribución atípica y rangos truncados

Las Figuras 5.3.1 y 5.3.2 muestran un salón con comportamiento atípico, primero con una vista acotada y luego en rango completo. Un detalle clave es que recortar el eje x cambia el soporte visible y puede inducir una lectura engañosa sobre ausencia/presencia de calificaciones bajas.




Figura 5.3.1: Distribución de calificaciones en un salón con valor atípico (vista acotada al rango 7.5–10).

En Figura 5.3.1 el eje x inicia en 7.5, lo que sugiere que en ese salón no aparecen calificaciones por debajo de ese umbral en la vista mostrada. Esto es compatible con un escenario donde prácticamente no hay reprobación (o donde la distribución observada está fuertemente concentrada en valores altos), aunque esa conclusión debe contrastarse con el dominio completo.




Figura 5.3.2: Distribución de calificaciones en un salón con valor atípico (vista en el rango completo de calificación).

En Figura 5.3.2 se re-expone el dominio completo; esto permite verificar si la aparente ausencia de valores bajos era real o un artefacto de la ventana acotada. La comparación entre ambas figuras funciona como control visual contra interpretaciones guiadas por recorte del eje.

5.4 Estandarización de imputación

La Figura 5.4.1 presenta la comparación de métodos en un marco estandarizado. La utilidad es doble: facilita contraste directo en una escala comparable y ayuda a separar cambios de forma (por imputación) de cambios puramente de escala.




Figura 5.4.1: Comparación de métodos estandarizados de imputación (eliminación, media y KDE) sobre la escala de calificación.

5.5 Heterogeneidad entre profesores

Las Figuras 5.5.1 y 5.5.2 muestran distribuciones por profesor. Estas visualizaciones motivan el control por aula: si un profesor concentra calificaciones cerca de 10 y otro cerca de 8, entonces comparar calificaciones crudas entre estudiantes de ambos entornos puede reflejar diferencias de severidad, no diferencias de desempeño relativo.




Figura 5.5.1: Distribución de calificaciones reportadas por profesor: densidades por docente y proporción de estudiantes (Reprobados: 9.43 %, Aprobados: 90.57 %).

En Figura 5.5.1 se reporta explícitamente “Reprobados: 9.43 %” y “Aprobados: 90.57 %”. El conjunto de curvas (una por docente) muestra variación en picos, dispersión y cola inferior; esto evidencia que la distribución de calificaciones no es homogénea entre profesores.

En Figura 5.5.2 las tasas cambian a “Reprobados: 20.33 %” y “Aprobados: 79.67 %”. Esto ilustra que la forma de tratar bajas (sin calificación) no es un detalle menor: puede modificar la masa en la zona baja y alterar proporciones agregadas. Por ello, las comparaciones posteriores en Z-score se interpretan como dependientes de la estrategia de imputación documentada, y KDE se usa para minimizar




Figura 5.5.2: Distribución de calificaciones por profesor con imputación KDE (Reprobados: 20.33 %, Aprobados: 79.67 %).

alteraciones estructurales (por ejemplo, evitar picos nuevos por imputación puntual).

5.6 Agrupamiento y distancias entre profesores

La Figura 5.6.1 incluye una matriz KS entre profesores y diagnósticos para elegir k en *k-medoids*. La idea es que las distribuciones de calificaciones por profesor pueden verse como “firmas”; comparar firmas con una métrica (KS) permite agrupar docentes con patrones similares.




Figura 5.6.1: Matriz de estadísticos KS entre profesores (IMPKDE) y criterios de selección de k para *k-medoids* (codo y *silhouette*).

En el panel de selección de k , el método del codo y el puntaje *silhouette* aportan criterios internos de validación: el primero busca un punto de rendimientos decrecientes en la inercia, y el segundo evalúa

separación/compacidad promedio. Estos diagnósticos son consistentes con la idea de que no hay una única forma “correcta” de agrupar, sino un rango plausible que debe interpretarse junto con evidencia sustantiva.




Figura 5.6.2: Visualización complementaria asociada al análisis de heterogeneidad docente (detalles no legibles en el PDF).

En Figura 5.6.2 no se distinguen detalles suficientes para describir ejes o leyendas con precisión; se conserva como soporte contextual del bloque de heterogeneidad docente, evitando inferencias no verificables.

5.7 Distribuciones por profesor: escenarios comparables

Las Figuras Figura 5.7.1–Figura 5.7.6 muestran distribuciones por profesor con imputación KDE en distintos escenarios/subconjuntos, con tasas impresas de reprobación/aprobación. La repetición de valores (por ejemplo, 9.73 %, 17.16 %, 32.89 %) en conjuntos de figuras sugiere que se están comparando particiones con métricas agregadas consistentes, aunque el criterio exacto no se distingue a nivel de panel.




Figura 5.7.1: Distribución por profesor con KDE: escenario A (Reprobados: 9.73 %, Aprobados: 90.27 %).

Estas figuras funcionan como diagnóstico de diversidad de patrones: escenarios con mayor tasa de reprobación suelen reflejar más masa en la cola inferior o un corrimiento global hacia valores más bajos. En adelante, este contexto justifica que el análisis principal use estandarización por aula y reporte contrastes robustos (no solo promedios), pues la forma de la distribución importa.




Figura 5.7.2: Distribución por profesor con KDE: escenario B (Reprobados: 17.16%, Aprobados: 82.84%).




Figura 5.7.3: Distribución por profesor con KDE: escenario C (Reprobados: 32.89%, Aprobados: 67.11%).




Figura 5.7.4: Distribución por profesor con KDE: escenario D (Reprobados: 9.73 %, Aprobados: 90.27 %).




Figura 5.7.5: Distribución por profesor con KDE: escenario E (Reprobados: 17.16 %, Aprobados: 82.84 %).




Figura 5.7.6: Distribución por profesor con KDE: escenario F (Reprobados: 32.89 %, Aprobados: 67.11 %).

6 ¿Cuál es la mejor forma de estandarizar?

La motivación para incluir el periodo dentro de la definición de aula se refuerza con evidencia temporal: si la forma de evaluar cambia a través de los periodos, mezclar periodos degrada la comparabilidad. Figura 6.0.1 muestra la media anual de calificaciones para un profesor en el rango 2019–2025, evidenciando variación longitudinal.




Figura 6.0.1: Media de calificaciones por profesor a lo largo de los periodos (ejemplo de variación temporal en el mismo docente).

Si el nivel promedio cambia por año, también es plausible que cambie la dispersión o incluso la forma (asimetría, colas). Por ello, la estandarización se realiza dentro de aula (docente–materia–periodo) y se agregan secciones cuando corresponden al mismo docente, materia y periodo. Esto reduce el sesgo por diferencias de severidad entre aulas y evita confundir cambios intertemporales de evaluación con diferencias de desempeño relativo entre estudiantes.

7 Análisis por aula (agregado por salón)

7.1 Relación visitas--Z-score (dispersión)




Figura 7.1.1: Relación entre número de visitas y calificación estandarizada (KDE, Z-score) agregada por aula.

En Figura 7.1.1 el eje x es el número de visitas (0–120) y el eje y es la calificación estandarizada (KDE, Z-score). La leyenda distingue los grupos de visitas. Como visualización, este diagrama no impone una relación funcional; sirve para inspeccionar dispersión, densidad de puntos en baja visita y presencia de casos en la cola de visitas altas. También permite evaluar si los puntos del grupo > 3 visitas tienden a concentrarse en valores de z más altos o si el patrón es heterogéneo.

7.2 Diferencia de medias (prueba t de Welch)




Figura 7.2.1: Comparación de distribuciones de calificación estandarizada por aula entre grupos de visitas (Welch t reportado en el panel: $t = 24,34$, $p = 0,0000$).

En Figura 7.2.1 se superponen densidades de Z-score para los dos grupos y se reporta $t = 24,34$ con $p = 0,0000$. Este resultado resume una diferencia promedio detectable en la escala estandarizada. La comparación visual de densidades aporta información adicional: desplazamientos hacia la derecha sugieren mayor desempeño relativo; diferencias en colas sugieren que el contraste puede concentrarse en ciertos tramos y no ser uniforme.

7.3 Pruebas robustas y tamaños de efecto




Figura 7.3.1: Comparación robusta por aula: medianas, pruebas no paramétricas y tamaños de efecto (valores anotados en el panel).

En Figura 7.3.1 se reporta, en el propio panel:

- Mediana (más de 3 visitas): 0.489; Mediana (3 o menos): 0.284; Diferencia: 0.205.
- IC95 % para diferencia de medianas: [0.190, 0.224].
- $p_{\text{mediana}} = 0,0003999$ (permutación para mediana).
- Mann-Whitney: $p = 4,958 \times 10^{-117}$; Brunner-Munzel: $p = 9,599 \times 10^{-122}$.
- Tamaños de efecto: $CL=0.620$, $r_{rb} = 0,240$, Cliff's $\delta = 0,243$.

Estas cantidades complementan la prueba t de medias. La mediana y su IC95 % describen una diferencia “típica” robusta a colas y valores extremos. Los tamaños de efecto (CL , r_{rb} , Cliff's δ) cuantifican magnitud práctica en escala de rangos/probabilidades, particularmente útil cuando hay grandes tamaños muestrales, donde el p -valor tiende a ser pequeño incluso para efectos modestos.

8 Análisis por estudiante (individual)

8.1 Relación visitas--Z-score (dispersión)




Figura 8.1.1: Relación entre número de visitas y calificación estandarizada (KDE, Z-score) a nivel estudiante.

En Figura 8.1.1 cada punto es un estudiante. Se observa alta variabilidad individual en Z-score, aun para el mismo número de visitas, lo cual es esperable: el desempeño depende de múltiples factores no observados en esta visualización. Aun así, la figura permite ver la concentración masiva de estudiantes en bajas visitas y la existencia de una cola de estudiantes con visitas altas, coherente con la distribución exploratoria.

8.2 Diferencia de medias (Welch t)




Figura 8.2.1: Comparación por estudiante entre grupos de visitas (valores anotados: $t = 21,93$, $p = 0,0000$, medias 0.34 vs -0.08 , diferencia 0.41 , $n = 1036$ vs $n = 9377$).

En Figura 8.2.1 se reporta:

- $t = 21,93$, $p = 0,0000$.

- Media (más de 3 visitas)=0.34; Media (3 o menos)=-0.08; Diferencia=0.41.
- Tamaños muestrales: $n = 1036$ y $n = 9377$.

La diferencia promedio de 0.41 en Z-score sugiere desplazamiento hacia valores mayores en el grupo con más de 3 visitas, en la escala estandarizada. El tamaño muestral grande ayuda a estimar con precisión la diferencia promedio; por ello se complementa con evidencia robusta y tamaños de efecto para interpretar magnitud.

8.3 Pruebas robustas, tamaños de efecto e IC95 %




Figura 8.3.1: Comparación robusta por estudiante: medianas, pruebas no paramétricas, tamaños de efecto e IC95 % (valores anotados en el panel).

En Figura 8.3.1 se reporta:

- Mediana (más de 3 visitas)=0.422; Mediana (3 o menos)=0.185; Diferencia=0.237.
- IC95 % para diferencia de medianas: [0.202, 0.284]; $p_{\text{mediana}} = 0,0003999$.
- Mann-Whitney: $p = 3,224 \times 10^{-50}$; Brunner-Munzel: $p = 2,023 \times 10^{-57}$.
- CL=0.641 (IC95 % [0.625, 0.657]); $r_{rb} = 0,282$ (IC95 % [0.250, 0.313]).
- Cliff's $\delta = 0,283$ (IC95 % [0.234, 0.326]).

La diferencia de medianas (0.237) es consistente con un desplazamiento hacia arriba del grupo con más visitas, con un IC95 % que no incluye 0. CL=0.641 puede interpretarse como una probabilidad de superioridad: al comparar un estudiante al azar del grupo > 3 visitas contra uno del grupo ≤ 3 , la probabilidad de que el primero tenga mayor Z-score es alrededor de 0.641 bajo la forma de cálculo del estimador.

9 Gráfica de desempeño

Esta sección resume la relación promedio entre visitas y desempeño estandarizado, con incertidumbre. La idea es complementar densidades y pruebas con una vista agregada por número de visitas, cuidando que en visitas altas hay menos observaciones (según Figura 3.1.1), lo que típicamente ensancha el intervalo de confianza.

9.1 Agregación de Z promedio por visitas con IC95 %




Figura 9.1.1: Z promedio por aula vs número de visitas, con intervalo de confianza del 95 % (IC95 %) alrededor de la media agregada.

En Figura 9.1.1 se grafica la media de Z por número de visitas y su IC95%. Cuando la media aumenta con visitas, sugiere una tendencia promedio positiva; cuando el IC se ensancha, indica menor precisión (habitualmente por menor tamaño muestral en ese nivel de visitas). Esta figura se interpreta como resumen descriptivo con incertidumbre: no sustituye las comparaciones por grupos, sino que ayuda a visualizar si el patrón se mantiene al agregar por conteo de visitas.

10 Conclusiones

10.1 Síntesis interpretativa

A nivel aula (Figura 7.2.1 y Figura 7.3.1) y a nivel estudiante (Figura 8.2.1 y Figura 8.3.1), las comparaciones muestran diferencias detectables entre grupos definidos por visitas (> 3 vs ≤ 3) en la escala estandarizada. El umbral de 3 visitas tiene interpretación institucional (puntos de PPA1), por lo que el contraste > 3 vs ≤ 3 separa uso adicional del mínimo incentivado. Los tamaños de efecto e intervalos de confianza aportan magnitud e incertidumbre, complementando los p -valores de pruebas paramétricas y no paramétricas.

10.2 Alcances y límites

La evidencia es observacional: describe asociación entre uso del CMAT y calificación estandarizada, pero no demuestra causalidad. La estandarización por aula (docente–materia–periodo) responde a heterogeneidad docente y cambios de evaluación en el tiempo, motivados visualmente por Figura 6.0.1. El tratamiento de “sin calificación” como bajas de materia y su imputación con KDE (comparado en Figura 5.2.1) se adopta para minimizar distorsiones de forma (por ejemplo, evitar picos nuevos por imputación puntual) y mantener comparabilidad en los análisis posteriores.