

Centro de Aprendizaje de Matemáticas

Universidad de las Américas Puebla

31 de marzo de 2026

Resumen

Este documento presenta una revisión estadística del uso del Centro de Aprendizaje de Matemáticas (CMAT) y de su asociación con el desempeño académico. La pregunta central es si, al comparar estudiantes con distintos niveles de asistencia al centro, aparecen diferencias sistemáticas en su rendimiento una vez que las calificaciones se vuelven comparables entre aulas. Para ello se trabaja con calificaciones estandarizadas por aula, es decir, con una medida que ubica a cada estudiante respecto del promedio y de la variación de su propio contexto docente.

El reporte conserva el recorrido analítico del estudio original. Primero describe la distribución de visitas al CMAT y justifica el corte entre estudiantes con estrictamente más de 3 visitas y aquellos con 3 visitas o menos. Después examina el tratamiento de registros sin calificación final, compara estrategias de imputación y documenta la variación en los patrones de calificación entre profesores y periodos. Finalmente, presenta comparaciones por aula y por estudiante mediante pruebas paramétricas y no paramétricas, tamaños de efecto e intervalos de confianza. En todo momento, la interpretación se mantiene en un plano observacional: los resultados describen asociaciones presentes en los datos, pero no establecen por sí solos una relación causal.

Índice

1	Panorama general	4
1.1	Pregunta y alcance	4
1.2	Definición operativa de “aula” (unidad de comparación)	4
1.3	Estructura del conjunto de datos y limpieza	4
1.4	Estandarización por aula: justificación y procedimiento	4
1.5	Criterio de agrupamiento por visitas (umbral 3)	5
2	Descripción del CMAT	6
3	Descripción de los Datos	7
3.1	Fuentes, cobertura y unidad analítica	7
3.2	Distribución y concentración de visitas	7
3.3	Cobertura temporal y estructura académica	8
3.4	Calificaciones, faltantes e imputación	10
4	Análisis exploratorio de datos	12
4.1	Distribución del número de visitas al CMAT	12
5	Comparación de desempeño entre grupos de visitas	13
5.1	Medición comparable del desempeño académico	13
5.2	Escala de comparación utilizada	13
6	Calificaciones	15
6.1	Interpretación de la categoría “sin calificación”	15
6.2	Comparación visual de estrategias de imputación	15
6.3	Casos especiales: distribución atípica y rangos truncados	16
6.4	Estandarización posterior a la imputación	16
6.5	Variación entre profesores en la distribución de calificaciones	17
6.6	Distancias y agrupamiento entre profesores	19
6.7	Distribuciones por profesor: escenarios comparables	19
7	Justificación de la estandarización por aula	22
8	Análisis por aula (agregado por salón)	23
8.1	Relación entre visitas y Z-score: dispersión	23
8.2	Comparación de medias con prueba t de Welch	23
8.3	Pruebas robustas y tamaños de efecto	24
9	Análisis por estudiante (individual)	26
9.1	Relación entre visitas y Z-score: dispersión	26
9.2	Comparación de medias con Welch t	26
9.3	Pruebas robustas, tamaños de efecto e IC95 %	28
10	Desempeño agregado por número de visitas	29
10.1	Agregación de Z promedio por visitas con IC95 %	29
11	Conclusiones	30
11.1	Síntesis interpretativa	30
11.2	Alcances y límites	30
A	Apéndice metodológico de técnicas estadísticas y de aprendizaje no supervisado	31
A.1	Notación general	31

A.2	Estandarización por aula	31
A.3	Tratamiento de faltantes e imputación por KDE	31
A.4	Curvas de densidad	31
A.5	Contraste paramétrico de medias: prueba t de Welch	32
A.6	Comparación de medianas y prueba de permutación	32
A.7	Pruebas no paramétricas de rangos	32
A.8	Tamaños de efecto	33
A.9	Intervalos de confianza	33
A.10	Heterogeneidad entre distribuciones docentes	33
A.11	Agrupamiento mediante k-medoids	33
A.12	Criterios de selección del número de grupos	34
A.13	Alcance inferencial	34

1 Panorama general

1.1 Pregunta y alcance

La pregunta que orienta este informe es observacional y puede formularse de la siguiente manera: si se agrupa a los estudiantes según su número de visitas al CMAT, ¿se observan diferencias sistemáticas en su desempeño académico cuando ese desempeño se mide en una escala comparable? La relevancia institucional de esta pregunta es clara, ya que permite examinar si un uso más frecuente del centro se asocia con un mejor posicionamiento relativo dentro de los cursos en los que participan los estudiantes.

Conviene subrayar desde el inicio que el propósito del documento no es atribuir causalidad de manera automática. Los datos disponibles describen registros académicos y visitas al servicio, pero no provienen de un diseño experimental controlado. Por esa razón, el análisis se concentra en identificar patrones, cuantificar su magnitud y explicitar la incertidumbre de las comparaciones, respetando la estructura real del sistema de información: docente, materia, periodo y condición de la calificación.

1.2 Definición operativa de “aula” (unidad de comparación)

Para este análisis se considera un “aula” como **un profesor impartiendo una materia en el mismo periodo, independientemente de si un profesor atiende más de una sección**. Esta definición no es un detalle operativo menor, sino una decisión necesaria para que la comparación sea justa. Dos grupos con el mismo profesor y la misma materia, dentro del mismo periodo, comparten un mismo marco de evaluación y pueden tratarse como una unidad analítica común.

En cambio, cuando un mismo profesor imparte la misma materia en periodos distintos, esas observaciones se consideran aulas distintas. La razón es que los criterios de evaluación, los niveles de exigencia o la distribución general de las calificaciones pueden cambiar con el tiempo. Incorporar el periodo dentro de la definición de aula permite capturar esas variaciones y evita mezclar, en una sola referencia, contextos docentes que ya no son plenamente comparables.

1.3 Estructura del conjunto de datos y limpieza

El conjunto analítico se construyó de manera que la unidad de observación quedara bien definida. Para cada combinación aula–estudiante se conserva un solo registro, con lo cual se evita contar dos veces a una misma persona dentro del mismo entorno de evaluación. Esta depuración es importante porque una duplicidad alteraría tanto los promedios como la forma de las distribuciones utilizadas en los análisis posteriores.

También se eliminaron los registros de estudiantes con doble licenciatura. La intención no es excluir trayectorias académicas relevantes, sino reducir la mezcla de recorridos curriculares que podrían seguir calendarios, cargas o condiciones de avance poco comparables con el resto de la población analizada. Del mismo modo, se conservaron las calificaciones de estudiantes reprobados, con baja voluntaria o con retiro temporal. Excluir esos casos produciría un **sesgo de supervivencia**, es decir, una distorsión que aparece cuando el análisis solo conserva a quienes lograron permanecer o concluir en condiciones favorables. Mantenerlos permite que las distribuciones por aula representen mejor el comportamiento real del sistema, incluyendo situaciones de bajo desempeño.

1.4 Estandarización por aula: justificación y procedimiento

El principal reto práctico del reporte es la comparabilidad. Una calificación de 8.5 no necesariamente representa el mismo nivel relativo en todos los cursos, porque los patrones de calificación pueden variar entre profesores e incluso para un mismo profesor en distintos periodos. Si se trabajara únicamente con calificaciones crudas, parte de la diferencia observada entre estudiantes podría reflejar el contexto de evaluación y no su posición relativa dentro del curso.

Para resolver este problema se utiliza una calificación estandarizada por aula. En términos simples, cada estudiante se compara con el promedio y la variación de su propio grupo. En estadística, esta medida se conoce como **Z-score**. Si g representa la calificación cruda y a identifica un aula, entonces se define:

$$z = \frac{g - \mu_a}{\sigma_a},$$

donde μ_a es la media del aula y σ_a su desviación estándar, calculadas bajo la estrategia de imputación elegida para tratar los faltantes. Con esta transformación, un valor positivo de z indica que el estudiante se ubica por arriba del promedio de su aula, mientras que un valor negativo indica que se ubica por debajo. La utilidad del procedimiento es que traslada todas las aulas a una misma escala de referencia, aun cuando las calificaciones originales no sean directamente comparables entre sí.

1.5 Criterio de agrupamiento por visitas (umbral 3)

El análisis utiliza un punto de corte operativo en 3 visitas para definir dos grupos: estudiantes con estrictamente más de 3 visitas y estudiantes con 3 visitas o menos. Esta separación responde, por un lado, a la forma observada en los datos, donde la mayor concentración se encuentra en niveles bajos de asistencia. Por otro lado, responde a una consideración institucional relevante: en algunos periodos, registrar 3 visitas al CMAT podía asociarse con la obtención de puntos de PPA1 para estudiantes de nuevo ingreso.

Bajo esta lógica, el grupo con 3 visitas o menos reúne tanto a quienes no utilizaron el servicio como a quienes tuvieron una participación nula o limitada, incluyendo posibles casos de cumplimiento del mínimo incentivado. En cambio, el grupo con estrictamente más de 3 visitas puede interpretarse como un uso adicional del centro, más allá de ese posible incentivo inicial. Esta distinción aporta claridad a las comparaciones posteriores, porque una diferencia favorable al grupo con estrictamente más de 3 visitas se alinea con un mayor aprovechamiento del servicio y no únicamente con el cumplimiento de un requisito mínimo.

2 Descripción del CMAT

El CMAT es un espacio de apoyo académico al que los estudiantes acuden para reforzar contenidos, resolver dudas y acompañar su proceso de aprendizaje en matemáticas. Dentro de este reporte, el número de visitas se utiliza como una medida de exposición al servicio. No se trata de una medida exhaustiva de todo lo que ocurre en el acompañamiento académico, pero sí ofrece un indicador observable y consistente para distinguir niveles de uso del centro.

La evidencia presentada a lo largo del documento debe leerse en términos asociativos. En otras palabras, el análisis describe cómo se relaciona el uso del CMAT con el desempeño relativo de los estudiantes dentro de sus aulas. Esa información es valiosa para la toma de decisiones institucionales, pero no implica por sí misma que el CMAT sea la causa única o directa de las diferencias observadas en las calificaciones.

3 Descripción de los Datos

3.1 Fuentes, cobertura y unidad analítica

Esta sección resume el conjunto analítico efectivamente utilizado en el reporte, construido solo a partir de los archivos `Materias_estudiantes-profesores_2019-2025_P_y_0.xlsx` y `Asesorias2024.xlsx`. La finalidad es dejar explícitas la cobertura, la limpieza, la unidad de observación y la escala de varias cantidades descriptivas antes de entrar al análisis comparativo.

El conjunto analítico del reporte se construyó a partir de `Materias_estudiantes-profesores_2019-2025_P_y_0.xlsx` y `Asesorias2024.xlsx`. Después de limpieza quedaron 26140 observaciones estudiante-aula, 10413 estudiantes, 77 profesores y 769 aulas definidas como profesor por variante de materia por año por sesión. La media de visitas por estudiante fue 1.234, la mediana fue 0.000, la proporción con cero visitas fue 71.910 % y la proporción con más de tres visitas fue 9.949 %.

La unidad básica del reporte no es el estudiante aislado ni la materia agregada, sino la observación **estudiante-aula**. En este documento, un aula queda definida por la combinación de profesor, variante de materia, año y sesión. Esta distinción es importante porque varias cantidades cambian según la unidad de análisis: por ejemplo, el número de visitas se define a nivel estudiante, mientras que la calificación imputada y estandarizada se observa a nivel estudiante-aula.

Cuadro 1: Conteos básicos del conjunto analítico utilizado en el reporte.

Concepto	Valor	Unidad
Filas crudas de materias	27788	filas
Filas crudas de asesorías	13500	filas
Observaciones estudiante-aula tras limpieza	26140	obs.
Estudiantes únicos	10413	estudiantes
Profesores únicos	77	profesores
Aulas únicas	769	aulas

La limpieza removió principalmente dos tipos de registros: filas duplicadas bajo la regla estudiante-materia-calificación y filas sin identificador de profesor. En términos acumulados, la depuración redujo 26,140 observaciones estudiante-aula y eliminó 5.9 % de las filas crudas de materias. La Tabla 2 resume estas etapas de forma compacta.

Cuadro 2: Resumen de los pasos de limpieza recuperables a partir del pipeline actual.

Paso	Filas eliminadas	% del paso previo	% acumulado desde el crudo
Entrada cruda	0	0.0 %	0.0 %
Eliminar duplicados estudiante-materia-calificación	1143	4.1 %	4.1 %
Eliminar columna NUMORDEN	0	0.0 %	4.1 %
Eliminar filas sin profesor	505	1.9 %	5.9 %
Normalizar ID de profesor	0	0.0 %	5.9 %

3.2 Distribución y concentración de visitas

La variable `VISITAS` del reporte se construye contando todas las asesorías observadas para cada estudiante en el archivo de asesorías y después mergeando ese total a cada fila limpia de materias. Por ello, `VISITAS` es una variable de exposición a **nivel estudiante** y no un conteo anual por sí mismo. Bajo esta definición, 71.9 % de los estudiantes tienen exactamente 0 visitas, 28.1 % registran al menos

1, 13.3 % registran al menos 3 y 9.95 % superan el umbral operativo de 3 visitas. El maximo observado es 116 visitas.

Cuadro 3: Distribucion de visitas en puntos de corte seleccionados.

k	Estudiantes con $V = k$	Proporcion con $V = k$	Proporcion con $V \geq k$	$E[V V \geq k]$
0	7488	71.9 %	100.0 %	1.234
1	1045	10.0 %	28.1 %	4.394
2	494	4.7 %	18.1 %	6.281
3	350	3.4 %	13.3 %	7.807
4	208	2.0 %	9.9 %	9.431
5	145	1.4 %	8.0 %	10.795
10	54	0.5 %	3.1 %	17.388
20	6	0.1 %	0.8 %	30.841




Figura 3.2.1: Descripcion grafica de la distribucion de visitas: histograma completo, histograma ampliado en conteos bajos, funcion acumulada empirica y curva de cola $P(V \geq k)$.

La concentracion del uso del servicio es marcada. El indice de Gini de visitas es 0.871; el top 1 % de estudiantes concentra 22.9 % de todas las visitas, el top 5 % concentra 56.0 % y el top 10 % concentra 76.2 %. Estos valores indican que el uso intensivo del CMAT existe, pero esta fuertemente concentrado en una minoria relativamente pequena de estudiantes.

3.3 Cobertura temporal y estructura academica

El conjunto limpio cubre 7 años, de 2019 a 2025. La mayor cantidad de estudiantes unicos en materias se observa en 2021, mientras que el mayor numero de eventos crudos de asesoria fechados aparece en 2023. Esta distincion es relevante: el conteo anual de asesorias proviene de la fecha del archivo de asesorias, pero la variable VISITAS usada en el reporte sigue siendo el conteo total por estudiante. Por




Figura 3.2.2: Continuacion de visitas $P(V \geq k + 1 | V \geq k)$ y curva de Lorenz de la distribucion de visitas.

Cuadro 4: Indicadores de concentracion y dispersion estructural de las visitas.

Indicador	Valor	Unidad
Gini de visitas	0.871	indice
Participacion del top 1 %	22.9 %	proporcion
Participacion del top 5 %	56.0 %	proporcion
Participacion del top 10 %	76.2 %	proporcion
Estudiantes en multiples aulas	65.2 %	proporcion
Media de aulas por estudiante	2.510	aulas
Mediana de aulas por estudiante	2.000	aulas

eso, en 2025 el conteo anual crudo de asesorías es 0, aunque los estudiantes activos ese año todavía pueden aparecer con VISITAS positivas debido a asesorías registradas en años previos.

Cuadro 5: Cobertura anual del conjunto analítico y estadísticos descriptivos de VISITAS entre estudiantes activos en cada año.

Año	Estudiantes	Profesores	Aulas	Media de VISITAS	Proporcion con 0 visitas	Eventos crudos de asesoria
2019	2827	51	108	1.487	64.7 %	2864
2020	3175	53	131	1.621	62.6 %	2220
2021	3265	56	147	1.216	69.6 %	1722
2022	2256	46	111	2.043	60.8 %	2474
2023	2287	42	106	2.224	58.8 %	3093
2024	2518	47	114	1.104	76.0 %	1127
2025	1438	36	52	0.219	93.7 %	0




Figura 3.3.1: A la izquierda, distribución de VISITAS entre estudiantes activos por año. A la derecha, distribución del tamaño de aula medido como número de estudiantes por aula.

En términos estructurales, el sistema analítico contiene 77 profesores y 769 aulas definidas por profesor, variante de materia, año y sesión. La mediana del tamaño de aula es 30 estudiantes y el máximo observado es 107. Además, 65.2 % de los estudiantes aparecen en múltiples aulas dentro del conjunto, con una media de 2.51 aulas por estudiante y una mediana de 2.00. Esto confirma que el reporte no observa trayectorias aisladas, sino recorridos académicos distribuidos en varios contextos docentes.

3.4 Calificaciones, faltantes e imputación

El bloque de calificaciones también requiere una descripción explícita porque el reporte combina calificación cruda, imputaciones y estandarización por aula. La versión numérica de la calificación cruda presenta 3,217 faltantes, equivalentes a 12.3 % de las observaciones estudiante–aula. En esta base, los tokens no numéricos más frecuentes asociados con ausencia de calificación son BV, RT y BA, con participaciones de 66.5 %, 30.8 % y 2.7 % dentro de ese subconjunto, respectivamente.

Cuadro 6: Resumen de variables de calificación utilizadas en el pipeline analítico.

Variable	Unidad	Faltantes	Media	Mediana	DE
Calificación cruda numérica	estudiante-aula	12.3 %	8.602	9.100	1.899
Imputación por media	estudiante-aula	0.6 %	8.136	8.900	2.274
Imputación por KDE	estudiante-aula	0.0 %	7.968	8.900	2.621
KDE estandarizada por aula	estudiante-aula	0.0 %	-0.000	0.320	0.985
Promedio estudiantil de Z-KDE	estudiante	0.0 %	-0.036	0.234	0.878

Cuadro 7: Tokens no numericos observados en la calificacion cruda.

Token	Conteo	Proporcion
BV	2138	66.5 %
RT	991	30.8 %
BA	88	2.7 %

La Tabla 6 muestra ademas que la imputacion por KDE y su version estandarizada eliminan faltantes a nivel estudiante-aula, mientras que el promedio estudiantil de Z-KDE queda completamente definido al colapsar por alumno. Esta seccion descriptiva no sustituye el analisis metodologico posterior sobre imputacion, pero si fija el contexto necesario para interpretar los resultados inferenciales que siguen.

4 Análisis exploratorio de datos

Antes de comparar resultados, conviene revisar la distribución de visitas al CMAT. Las Figuras Figura 4.1.1 y Figura 4.1.2 muestran esa estructura básica. Esta revisión inicial es importante porque el patrón de uso del servicio condiciona la interpretación de cualquier contraste posterior: no es lo mismo comparar dos grupos de tamaño similar que comparar un grupo pequeño de uso frecuente contra una mayoría amplia de uso bajo o nulo.

Además, la forma de la distribución aporta información sobre la naturaleza de la variable. Cuando muchas observaciones se concentran cerca de 0 y solo unas pocas alcanzan valores altos, se habla de una distribución asimétrica con cola larga. En contextos así, un promedio simple puede ocultar rasgos relevantes del comportamiento real de los datos.

4.1 Distribución del número de visitas al CMAT

En Figura 4.1.1 el histograma concentra la mayor parte de las observaciones en números bajos de visitas, incluyendo 0, y presenta una cola larga que se extiende aproximadamente hasta 120 visitas. Lo primero que debe observar el lector es precisamente ese contraste: el uso intensivo del CMAT existe, pero representa una fracción reducida frente al uso bajo o inexistente.

Desde el punto de vista estadístico, esta figura muestra una distribución fuertemente asimétrica y con valores extremos. Por ello, el análisis posterior evita resumir el comportamiento del servicio con una sola media de visitas y prefiere una partición por umbral que permita distinguir entre un uso limitado y un uso más sostenido del centro.




Figura 4.1.1: Histograma del número de visitas al CMAT por estudiante.

La Figura 4.1.2 presenta la misma distribución, pero ahora separada en dos grupos: estudiantes con estrictamente más de 3 visitas (9.95 %) y estudiantes con 3 visitas o menos (90.05 %). Esta segunda visualización permite ubicar con claridad el punto de corte que se utilizará en el resto del documento.

La utilidad del umbral es doble. Por una parte, separa un uso adicional del servicio respecto de un uso muy limitado. Por otra, recoge la consideración institucional de que 3 visitas podían estar vinculadas con PPA1 en ciertos periodos. La consecuencia práctica es un desbalance importante entre tamaños muestrales, por lo que más adelante no solo se reportan pruebas de significancia, sino también tamaños de efecto e intervalos de confianza que ayudan a valorar la magnitud y la precisión de las diferencias.




Figura 4.1.2: Histograma del número de visitas al CMAT con partición por umbral de 3 visitas: estrictamente más de 3 frente a 3 visitas o menos.

5 Comparación de desempeño entre grupos de visitas

A partir del umbral mostrado en Figura 4.1.2, el análisis contrasta el desempeño de dos grupos: quienes registran estrictamente más de 3 visitas al CMAT y quienes registran 3 visitas o menos. Esta separación no se adopta solo por conveniencia descriptiva. También permite distinguir, dentro de lo posible, entre un uso adicional del servicio y un uso que podría estar asociado con el cumplimiento de un mínimo institucional.

La pregunta que guía esta sección es si ambos grupos ocupan posiciones distintas dentro de las distribuciones de calificación de sus respectivas aulas. La respuesta no se busca en calificaciones crudas, sino en una escala comparable. Por esa razón, antes de presentar resultados se explican dos decisiones metodológicas previas: cómo se tratan los casos sin calificación final y por qué se estandariza el desempeño por aula.

5.1 Medición comparable del desempeño académico

Antes de comparar grupos por visitas, es necesario atender dos obstáculos que afectan directamente la comparabilidad. El primero es la presencia de registros “sin calificación”, que obligan a decidir si esos casos deben excluirse o si conviene asignarles un valor plausible mediante algún procedimiento de imputación. El segundo es la **heterogeneidad** entre aulas, es decir, la existencia de diferencias en la forma de evaluar, en la dispersión de las calificaciones o en la distribución general de notas entre profesores y periodos.

El orden de estas decisiones es importante. Si se compararan calificaciones crudas sin resolver primero el tratamiento de faltantes y sin controlar por aula, el análisis podría mezclar fenómenos distintos: diferencias genuinas en desempeño relativo, diferencias en los criterios de evaluación y diferencias derivadas de cómo se maneja la ausencia de calificación final. El objetivo del reporte es precisamente evitar esa confusión.

5.2 Escala de comparación utilizada

La comparación principal se hace con las calificaciones finales, pero no en su escala original. Se utiliza la versión estandarizada por aula, expresada mediante Z-score, y una estrategia explícita para tratar los casos sin calificación final. Esto permite formular la pregunta de manera más precisa: dentro de

contextos docentes comparables, ¿los estudiantes con estrictamente más de 3 visitas tienden a ubicarse más arriba en la distribución de su propio grupo que los estudiantes con 3 visitas o menos?

Con este encuadre, los resultados posteriores no deben leerse como una comparación entre cursos o entre profesores, sino como una comparación entre posiciones relativas dentro de cada aula. Esa diferencia conceptual es clave para que la interpretación institucional del documento sea sólida y prudente.

6 Calificaciones

6.1 Interpretación de la categoría “sin calificación”

En este conjunto de datos, la categoría “sin calificación” corresponde a estudiantes que **dieron de baja la materia**. En consecuencia, no se trata de una ausencia puramente administrativa o de un dato faltante sin contexto, sino de un evento académico con significado propio dentro de la trayectoria del estudiante.

Esta precisión es importante porque la baja de una materia suele asociarse con circunstancias específicas, como ajustes de carga, decisiones estratégicas o la expectativa de un resultado desfavorable. Por ello, estos registros no deben tratarse como si faltaran al azar. La manera en que se incorporan o se excluyen puede modificar de forma sustantiva la distribución final de calificaciones y, con ello, las comparaciones posteriores.

6.2 Comparación visual de estrategias de imputación

Cuando en una base de datos falta una calificación y se decide conservar el registro en el análisis, es necesario asignarle un valor de referencia. A este procedimiento se le llama **imputación**. La Figura 6.2.1 compara tres alternativas para hacerlo en un salón: eliminar los casos sin calificación, imputar con la media del grupo o imputar mediante **Kernel Density Estimation (KDE)**, es decir, una estimación de densidad por kernel.

La intuición detrás de KDE es la siguiente: en vez de colocar todos los faltantes en un solo valor, se reconstruye una curva suave a partir de las calificaciones observadas y se utilizan valores consistentes con esa forma general. Esto ayuda a conservar la estructura de la distribución. En cambio, imputar con un único valor fijo, como la media del salón, puede producir picos artificiales que no estaban presentes en los datos originales.

Conviene precisar qué es un **kernel**. En este contexto, un kernel es una función suave, generalmente simétrica, que coloca más peso en los valores cercanos a cada observación y menos peso en los alejados. Puede imaginarse como una pequeña “campana” centrada en cada calificación observada. Al superponer todas esas campanas se obtiene una curva continua que aproxima la forma general de la distribución sin obligar a que todos los casos se acumulen en un mismo punto.

Formalmente, si $x_1, \dots, x_n$ son observaciones de calificación y K es un kernel, la densidad estimada se escribe como

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

donde h es un ancho de banda positivo. En términos simples, h controla el nivel de suavizado: valores pequeños siguen con más detalle las irregularidades locales y valores grandes producen curvas más suaves. En este reporte, KDE se adopta porque permite imputar sin concentrar masa artificial en un punto específico y, con ello, reduce alteraciones fuertes en la forma de la distribución.

Las curvas de esta figura, y de otras similares a lo largo del reporte, son **curvas de densidad**. El eje vertical no representa número de estudiantes ni porcentaje directo. Representa concentración relativa de observaciones por unidad de calificación. Por ello, una densidad puede tomar valores por encima de 1 cuando muchas calificaciones se concentran en un intervalo estrecho. Esto no significa que exista “más de 100 %” de estudiantes en esa zona; significa, simplemente, que la distribución está muy concentrada allí. Lo importante es que el área total bajo cada curva sea 1. En términos de lectura visual, una curva alta y angosta indica mayor concentración, mientras que una curva más baja y extendida indica mayor dispersión.




Figura 6.2.1: Comparación de métodos de imputación de calificaciones para un salón: eliminación, imputación por media e imputación por KDE.

6.3 Casos especiales: distribución atípica y rangos truncados

Las Figuras Figura 6.3.1 y Figura 6.3.2 muestran un caso con comportamiento atípico. Este bloque se incluye porque, en análisis institucionales, no basta con observar una distribución; también es necesario revisar cómo cambia la interpretación cuando el eje horizontal se presenta acotado o en su rango completo.

En Figura 6.3.1 el eje x inicia en 7.5. Esa decisión visual puede dar la impresión de que no existen calificaciones por debajo de ese valor o de que la distribución está enteramente concentrada en la zona alta. La lectura, sin embargo, debe mantenerse provisional mientras no se revise el soporte completo.




Figura 6.3.1: Distribución de calificaciones en un salón con valor atípico (vista acotada al rango 7.5–10).

La Figura 6.3.2 reexpone el mismo caso en el dominio completo de la escala de calificación. Lo que debe observarse aquí es si la aparente ausencia de valores bajos era una propiedad real del salón o un efecto del recorte gráfico. La comparación entre ambas figuras funciona como una verificación visual contra interpretaciones apresuradas inducidas por la presentación del eje.

6.4 Estandarización posterior a la imputación

La Figura 6.4.1 retoma la comparación entre métodos de imputación, pero ahora dentro de un marco estandarizado. Esta visualización es útil porque separa dos cuestiones que a veces se confunden:




Figura 6.3.2: Distribución de calificaciones en un salón con valor atípico (vista en el rango completo de calificación).

los cambios puramente de escala y los cambios en la forma de la distribución.

Al llevar todos los métodos a una referencia comparable, resulta más sencillo identificar si una estrategia altera el centro, la dispersión o la estructura general de las calificaciones. En términos prácticos, la figura ayuda a justificar que la decisión de imputación no es un trámite técnico aislado, sino una parte sustantiva del análisis.




Figura 6.4.1: Comparación de métodos estandarizados de imputación (eliminación, media y KDE) sobre la escala de calificación.

6.5 Variación entre profesores en la distribución de calificaciones

Las Figuras 6.5.1 y 6.5.2 muestran cómo cambian las distribuciones de calificaciones entre profesores. El objetivo de este bloque es documentar la existencia de contextos de evaluación distintos. Si un docente concentra calificaciones cerca de 10 y otro alrededor de 8, comparar de manera directa a estudiantes de ambos entornos puede reflejar diferencias en la distribución de notas y no necesariamente diferencias equivalentes en desempeño relativo.

Estas figuras también deben leerse como gráficas de densidad. Por ello, la altura de las curvas no representa una proporción directa de estudiantes, sino concentración relativa. Cuando una curva rebasa el valor 1 en el eje vertical, lo que muestra es que muchas calificaciones se encuentran comprimidas en un tramo pequeño de la escala, no que el grupo tenga una proporción imposible.

En Figura 6.5.1 se reportan explícitamente las proporciones agregadas de reprobación (9.43 %) y




Figura 6.5.1: Distribución de calificaciones reportadas por profesor: densidades por docente y proporción de estudiantes (Reprobados: 9.43 %, Aprobados: 90.57 %).

aprobación (90.57 %). Más allá de esos porcentajes, lo importante es observar que las curvas por docente no tienen la misma forma: cambian sus picos, su dispersión y el peso de la cola inferior. Esa diversidad es una evidencia visual de heterogeneidad en los patrones de calificación.




Figura 6.5.2: Distribución de calificaciones por profesor con imputación KDE (Reprobados: 20.33 %, Aprobados: 79.67 %).

En Figura 6.5.2 las proporciones cambian a 20.33 % de reprobados y 79.67 % de aprobados. Esta diferencia muestra que la forma de tratar las bajas no es un detalle menor: puede modificar la masa de la distribución en la zona baja y alterar indicadores agregados. Por ello, los análisis posteriores se interpretan siempre en el marco de la estrategia de imputación documentada y no como si esa decisión fuera neutra.

6.6 Distancias y agrupamiento entre profesores

La Figura 6.6.1 profundiza en la variación entre profesores mediante una matriz de distancias y un análisis de agrupamiento. La idea es tratar la distribución de calificaciones de cada docente como una “firma” y comparar esas firmas entre sí.

La medida utilizada es el estadístico **KS**, abreviatura de Kolmogorov–Smirnov. En términos sencillos, este estadístico resume qué tan separadas están dos distribuciones acumuladas; valores mayores indican diferencias más marcadas entre los patrones de calificación comparados. A partir de esa matriz se realiza un **clustering** o agrupamiento, es decir, un procedimiento para reunir profesores con distribuciones semejantes. El método empleado es *k-medoids*, cercano en espíritu a *k-means*, pero más estable frente a valores atípicos porque cada grupo queda representado por un caso observado y no por un promedio abstracto.




Figura 6.6.1: Matriz de estadísticos KS entre profesores (IMPKDE) y criterios de selección de *k* para *k-medoids* (codo y *silhouette*).

La elección de *k*, es decir, del número de grupos, se apoya en dos diagnósticos internos. El método del codo busca el punto a partir del cual aumentar el número de grupos aporta cada vez menos mejora. El índice *silhouette* resume qué tan compactos y qué tan bien separados quedan los grupos formados. Ninguno de estos criterios debe interpretarse como una regla automática o única; más bien ofrecen una guía cuantitativa para respaldar la lectura sustantiva de la heterogeneidad docente.

En Figura 6.6.2 no es posible distinguir con suficiente claridad los ejes o las leyendas en la versión disponible del PDF. Por ello, la figura se conserva como referencia contextual del bloque, pero sin extraer de ella inferencias específicas que no puedan verificarse con certeza.

6.7 Distribuciones por profesor: escenarios comparables

Las Figuras 6.7.1 y 6.7.2 presentan distribuciones por profesor con imputación KDE en tres particiones comparables, organizadas en paneles de izquierda a derecha. En todas ellas se reportan proporciones agregadas de reprobación y aprobación. La finalidad de este conjunto no es introducir un resultado aislado, sino mostrar que la diversidad de patrones persiste aun cuando se observan configuraciones distintas del conjunto de datos.

La repetición de ciertas tasas entre paneles sugiere que las figuras comparan particiones con métricas agregadas consistentes. Aun cuando cada panel resume un subconjunto diferente de profesores,




Figura 6.6.2: Visualización complementaria asociada al análisis de heterogeneidad docente (detalles no legibles en el PDF).




Figura 6.7.1: Distribuciones por profesor con imputación KDE en formato panel (1×3). De izquierda a derecha se muestran los tres clusters docentes comparables, cada uno con sus proporciones agregadas de reprobación y aprobación.




Figura 6.7.2: Distribuciones por profesor con imputación KDE e intervalos de confianza en formato panel (1×3). De izquierda a derecha se muestran los mismos tres clusters docentes, ahora con bandas de incertidumbre alrededor de cada curva.

el mensaje general sí es claro: existen escenarios con mayor concentración de masa en la cola inferior y otros con distribuciones desplazadas hacia valores más altos. En adelante, este diagnóstico refuerza la necesidad de trabajar con estandarización por aula y con contrastes que no dependan únicamente de la media.

7 Justificación de la estandarización por aula

La conveniencia de incluir el periodo dentro de la definición de aula se refuerza con evidencia temporal. La Figura 7.0.1 muestra la media de calificaciones de un mismo profesor a lo largo de varios periodos entre 2019 y 2025. El propósito de este ejemplo no es describir un caso excepcional, sino ilustrar que el patrón de calificación de un docente puede cambiar con el tiempo.




Figura 7.0.1: Media de calificaciones por profesor a lo largo de los periodos (ejemplo de variación temporal en el mismo docente).

Si el nivel promedio varía entre años, también es razonable pensar que cambien la dispersión y, en algunos casos, la forma completa de la distribución. Por ello, mezclar periodos dentro de una misma referencia puede degradar la comparabilidad del análisis. La estandarización dentro de aula, entendida como docente–materia–periodo, busca justamente evitar ese problema.

Esta decisión no elimina toda la variabilidad del sistema, pero sí reduce una fuente importante de confusión. En términos institucionales, permite que la comparación se haga entre estudiantes ubicados en contextos de evaluación más homogéneos y evita atribuir a diferencias de desempeño relativo lo que en realidad podría deberse a cambios en los patrones de calificación entre periodos.

8 Análisis por aula (agregado por salón)

En esta sección la unidad de observación es el aula ya definida anteriormente. En lugar de comparar directamente a todos los estudiantes entre sí, se resume el comportamiento dentro de cada entorno docente y posteriormente se contrastan los grupos de visitas. Esta perspectiva es útil porque reduce el peso desproporcionado que podrían tener las aulas con mayor matrícula y permite verificar si el patrón general se sostiene también a nivel agregado.

8.1 Relación entre visitas y Z-score: dispersión




Figura 8.1.1: Relación entre número de visitas y calificación estandarizada (KDE, Z-score) agregada por aula.

En Figura 8.1.1 el eje horizontal muestra el número de visitas y el eje vertical la calificación estandarizada. La figura no impone una forma funcional específica; su función es descriptiva. Lo que debe observarse es la concentración de aulas en niveles bajos de visita, la presencia de una cola de visitas altas y la ubicación relativa de los puntos de acuerdo con su Z-score.

Esta visualización también ayuda a valorar si las aulas asociadas con estrictamente más de 3 visitas tienden a concentrarse en valores de z más altos o si el patrón es más heterogéneo. Por sí sola no prueba una diferencia, pero prepara la lectura de los contrastes formales que se presentan a continuación.

8.2 Comparación de medias con prueba t de Welch

La Figura 8.2.1 compara las distribuciones de Z-score entre aulas asociadas con estrictamente más de 3 visitas y aulas asociadas con 3 visitas o menos. La prueba utilizada es la t de Welch, un contraste de medias diseñado para situaciones en las que los grupos pueden tener tamaños distintos y varianzas diferentes. El panel reporta $t = 24,34$ y $p = 0,0000$. El p -valor resume qué tan compatible sería un resultado de esta magnitud con un escenario en el que no existiera diferencia promedio entre grupos; en este caso, el valor reportado sugiere una diferencia claramente detectable en la muestra analizada.

La lectura no debe detenerse en la significancia estadística. La superposición de densidades permite observar hacia dónde se desplazan las distribuciones y si la diferencia parece concentrarse en el centro o también en las colas. Un corrimiento hacia la derecha del grupo con mayor número de visitas es consistente con un mejor desempeño relativo en la escala estandarizada, aunque siempre dentro de una interpretación asociativa y no causal. En esta figura, como en las demás curvas de densidad, el eje




Figura 8.2.1: Comparación de distribuciones de calificación estandarizada por aula entre grupos de visitas (prueba t de Welch reportada en el panel: $t = 24,34$, $p = 0,0000$).

vertical muestra concentración relativa y no porcentaje directo; por ello, una altura mayor que 1 no implica un exceso de casos, sino una mayor concentración en un intervalo estrecho de valores.

8.3 Pruebas robustas y tamaños de efecto




Figura 8.3.1: Comparación robusta por aula: medianas, pruebas no paramétricas y tamaños de efecto (valores anotados en el panel).

La Figura 8.3.1 complementa la comparación de medias con herramientas más robustas, es decir, menos sensibles a colas largas o a valores extremos. El panel reporta una mediana de 0.489 para el grupo con estrictamente más de 3 visitas y de 0.284 para el grupo con 3 visitas o menos, con una diferencia de 0.205. El intervalo de confianza del 95 % (IC95 %) para esa diferencia es [0.190, 0.224], y la prueba de permutación para medianas arroja $p_{mediana} = 0,0003999$. Un intervalo de confianza puede entenderse como un rango de valores plausibles para la diferencia poblacional compatible con la evidencia observada bajo el procedimiento utilizado.

Además se reportan dos pruebas no paramétricas: **Mann-Whitney**, con $p = 4,958 \times 10^{-117}$, y

Brunner–Munzel, con $p = 9,599 \times 10^{-122}$. Ambas comparan la posición relativa de los grupos a partir de rangos, por lo que son útiles cuando se desea reducir la dependencia respecto de supuestos paramétricos estrictos. Junto a ellas aparecen varios **tamaños de efecto**, es decir, medidas de magnitud práctica. En particular, $CL = 0,620$ se interpreta como una probabilidad de superioridad en lenguaje simple; $r_{rb} = 0,240$ y Cliff's $\delta = 0,243$ resumen el grado de separación entre ambas distribuciones. En conjunto, estos indicadores muestran que la diferencia no solo es estadísticamente detectable, sino también consistente cuando se examina desde métricas robustas.

9 Análisis por estudiante (individual)

La sección anterior trabajó con aulas agregadas. Ahora el foco vuelve al nivel individual para examinar si el patrón persiste cuando cada observación corresponde a un estudiante. Esta segunda mirada es relevante porque recupera toda la variabilidad de la población estudiantil y permite valorar si la asociación observada a nivel agregado también aparece en los datos individuales.

9.1 Relación entre visitas y Z-score: dispersión




Figura 9.1.1: Relación entre número de visitas y calificación estandarizada (KDE, Z-score) a nivel estudiante.

En Figura 9.1.1 cada punto representa a un estudiante. La primera impresión es la alta variabilidad individual del Z-score, incluso entre estudiantes con un número similar de visitas. Esto es esperable, ya que el desempeño académico depende de múltiples factores que no están contenidos en esta sola visualización.

Al mismo tiempo, la figura confirma dos rasgos ya observados: la concentración masiva en niveles bajos de visita y la existencia de una cola de estudiantes con uso intensivo del CMAT. La gráfica, por tanto, no pretende establecer una relación lineal simple, sino mostrar la amplitud de la dispersión sobre la cual se realizan las comparaciones formales.

9.2 Comparación de medias con Welch t

En Figura 9.2.1 se presenta nuevamente la prueba t de Welch, ahora a nivel estudiante. El panel reporta $t = 21,93$ y $p = 0,0000$, junto con medias de 0.34 para el grupo con estrictamente más de 3 visitas y de -0.08 para el grupo con 3 visitas o menos, con una diferencia reportada de 0.41. Los tamaños muestrales son $n = 1036$ y $n = 9377$, respectivamente.

En una escala estandarizada, esta diferencia promedio describe un desplazamiento del grupo con mayor número de visitas hacia valores más altos de desempeño relativo. El tamaño muestral amplio permite estimar esa diferencia con alta precisión estadística; sin embargo, precisamente por ello resulta indispensable complementar la lectura con medidas robustas y con tamaños de efecto, para no confundir detectabilidad estadística con relevancia práctica.




Figura 9.2.1: Comparación por estudiante entre grupos de visitas (valores anotados: $t = 21,93$, $p = 0,0000$, medias 0.34 vs -0.08 , diferencia 0.41 , $n = 1036$ vs $n = 9377$).




Figura 9.3.1: Comparación robusta por estudiante: medianas, pruebas no paramétricas, tamaños de efecto e IC95 % (valores anotados en el panel).

9.3 Pruebas robustas, tamaños de efecto e IC95 %

La Figura 9.3.1 refuerza la lectura anterior desde estadísticos robustos. La mediana del grupo con estrictamente más de 3 visitas es 0.422, mientras que la del grupo con 3 visitas o menos es 0.185; la diferencia es 0.237. El IC95 % para esa diferencia es [0.202, 0.284] y la prueba de permutación para la mediana reporta $p_{\text{mediana}} = 0,0003999$. De nuevo, el hecho de que el intervalo no incluya 0 es consistente con una diferencia positiva entre grupos.

Las pruebas de Mann–Whitney y Brunner–Munzel reportan, respectivamente, $p = 3,224 \times 10^{-50}$ y $p = 2,023 \times 10^{-57}$. En cuanto a tamaños de efecto, se informa $CL = 0,641$ con IC95 % [0.625, 0.657], $r_{rb} = 0,282$ con IC95 % [0.250, 0.313] y Cliff's $\delta = 0,283$ con IC95 % [0.234, 0.326]. En lenguaje más intuitivo, el valor $CL = 0,641$ puede leerse como una probabilidad de superioridad: al comparar aleatoriamente un estudiante del grupo con estrictamente más de 3 visitas contra uno del grupo con 3 visitas o menos, la probabilidad estimada de que el primero tenga mayor Z-score es cercana a 0.641. En conjunto, estas medidas describen una separación moderada y consistente entre ambos grupos dentro de la escala estandarizada.

10 Desempeño agregado por número de visitas

Esta sección ofrece una síntesis gráfica de la relación entre visitas y desempeño estandarizado. La intención es complementar las comparaciones por grupos con una vista agregada por número de visitas específico. Dado que los niveles altos de asistencia son mucho menos frecuentes, también es esperable que la incertidumbre aumente en esa zona.

10.1 Agregación de Z promedio por visitas con IC95 %




Figura 10.1.1: Z promedio por aula frente al número de visitas, con intervalo de confianza del 95 % (IC95 %) alrededor de la media agregada.

En Figura 10.1.1 se grafica la media de Z para cada número de visitas y se añade su IC95 %. Lo que conviene observar es si la trayectoria promedio asciende, desciende o se mantiene estable conforme aumenta el número de visitas. Cuando la media crece, la lectura descriptiva es que los niveles mayores de asistencia se asocian con mejor desempeño relativo promedio.

El ancho del intervalo de confianza aporta información adicional sobre precisión. Un intervalo más amplio suele reflejar que en ese nivel de visitas hay menos observaciones disponibles. Por ello, esta figura debe leerse como un resumen descriptivo con incertidumbre y no como sustituto de las comparaciones por grupos realizadas en las secciones anteriores.

11 Conclusiones

11.1 Síntesis interpretativa

Tanto a nivel aula (Figura 8.2.1 y Figura 8.3.1) como a nivel estudiante (Figura 9.2.1 y Figura 9.3.1), el análisis muestra diferencias detectables entre los grupos definidos por visitas al CMAT. En la escala estandarizada utilizada, los estudiantes con estrictamente más de 3 visitas tienden a ubicarse, en promedio y también en términos robustos, por arriba de quienes registran 3 visitas o menos.

La interpretación de este hallazgo gana claridad porque el umbral de 3 visitas tiene un sentido institucional concreto. El contraste entre estrictamente más de 3 visitas y 3 visitas o menos no solo separa dos conteos numéricos, sino dos formas de uso potencialmente distintas del servicio: un uso adicional del CMAT frente a un uso nulo, limitado o posiblemente vinculado al cumplimiento de un mínimo. Los tamaños de efecto y los intervalos de confianza complementan a los p -valores y permiten sostener que la diferencia observada no depende únicamente del gran tamaño muestral.

11.2 Alcances y límites

La evidencia presentada es observacional. En consecuencia, describe asociaciones entre el uso del CMAT y la calificación estandarizada, pero no demuestra por sí sola una relación causal. La prudencia en esta interpretación es especialmente importante en un contexto académico donde intervienen múltiples factores adicionales, como antecedentes formativos, características del curso, decisiones de inscripción o condiciones personales del estudiante.

La estandarización por aula, entendida como docente–materia–periodo, se adopta para responder a la variación entre contextos de evaluación y a los cambios que pueden presentarse en el tiempo, tal como se ilustra en Figura 7.0.1. Asimismo, el tratamiento de la categoría “sin calificación” como baja de materia y su imputación mediante KDE, comparada en Figura 6.2.1, busca conservar mejor la forma de las distribuciones y evitar distorsiones introducidas por imputaciones puntuales. En conjunto, estas decisiones metodológicas fortalecen la comparabilidad del análisis y dan mayor solidez al uso institucional del reporte.

A Apéndice metodológico de técnicas estadísticas y de aprendizaje no supervisado

Este apéndice reúne, en formato sintético y formal, la notación, las definiciones operativas, los estadísticos y las expresiones principales de los métodos empleados a lo largo del reporte. Su finalidad es dejar explícito el andamiaje metodológico del documento y facilitar una lectura técnica homogénea del análisis.

A.1 Notación general

Sea g la calificación cruda de un estudiante y sea a el aula definida por la combinación docente–materia–periodo. Sean μ_a y σ_a la media y la desviación estándar de las calificaciones en el aula a . Para las comparaciones entre grupos, se denota por G_1 al conjunto de observaciones con estrictamente más de 3 visitas al CMAT y por G_0 al conjunto con 3 visitas o menos. Sus tamaños muestrales se representan por n_1 y n_0 , respectivamente.

A.2 Estandarización por aula

La variable de respuesta principal del reporte es la calificación estandarizada por aula:

$$z = \frac{g - \mu_a}{\sigma_a}.$$

Esta transformación convierte cada calificación en una posición relativa respecto de su propio entorno de evaluación. Bajo esta convención, $z = 0$ corresponde al promedio del aula, $z > 0$ indica un desempeño relativo por encima del promedio y $z < 0$ un desempeño relativo por debajo de él. La estandarización se realiza dentro de cada aula para reducir problemas de comparabilidad derivados de diferencias entre docentes, materias y periodos.

A.3 Tratamiento de faltantes e imputación por KDE

Los registros “sin calificación” se interpretan como bajas de materia. Cuando tales registros se incorporan al análisis mediante imputación, se compara la eliminación simple, la imputación por media y la imputación basada en estimación de densidad por kernel.

La densidad estimada por KDE se escribe como

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

donde $x_1, \dots, x_n$ son las calificaciones observadas, K es el kernel y h es el ancho de banda. El kernel actúa como una función de ponderación local centrada en cada observación; el ancho de banda controla el nivel de suavizado. En el presente contexto, KDE se utiliza para preservar la forma global de la distribución al imputar faltantes, evitando la acumulación artificial de masa en un valor único.

A.4 Curvas de densidad

En las figuras que muestran densidades, el eje vertical no representa frecuencia absoluta ni porcentaje directo de estudiantes. Representa densidad de probabilidad. Por ello, la altura de una curva puede ser mayor que 1 sin contradecir la interpretación probabilística, siempre que el área total bajo la curva sea igual a 1:

$$\int_{-\infty}^{\infty} f(x) dx = 1.$$

Una curva más alta y angosta indica mayor concentración de observaciones en un intervalo reducido; una curva más baja y extendida indica mayor dispersión.

A.5 Contraste paramétrico de medias: prueba t de Welch

Para contrastar medias entre G_1 y G_0 se emplea la prueba t de Welch, apropiada cuando los grupos pueden diferir tanto en tamaño como en varianza. El estadístico se define como

$$t = \frac{\bar{z}_1 - \bar{z}_0}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_0^2}{n_0}}},$$

donde $\bar{z}_j$ y s_j^2 son la media y la varianza muestral del grupo G_j . Los grados de libertad se aproximan mediante la corrección de Welch–Satterthwaite:

$$v \approx \frac{\left(\frac{s_1^2}{n_1} + \frac{s_0^2}{n_0}\right)^2}{\frac{\left(\frac{s_1^2}{n_1}\right)^2}{n_1 - 1} + \frac{\left(\frac{s_0^2}{n_0}\right)^2}{n_0 - 1}}.$$

El contraste se interpreta como una prueba de diferencia de medias bajo independencia entre observaciones y sin requerir homogeneidad de varianzas.

A.6 Comparación de medianas y prueba de permutación

Como complemento robusto a la comparación de medias, el reporte utiliza la diferencia de medianas

$$\Delta_{\text{med}} = \text{Med}(G_1) - \text{Med}(G_0),$$

y una prueba de permutación asociada. Bajo esta estrategia, la hipótesis nula se evalúa reordenando aleatoriamente las etiquetas de grupo y recalculando repetidamente el estadístico de interés. El valor- p se obtiene como la proporción de permutaciones que generan una diferencia al menos tan extrema como la observada. Este procedimiento resulta útil cuando se desea reducir la dependencia respecto de supuestos paramétricos clásicos.

A.7 Pruebas no paramétricas de rangos

La prueba de Mann–Whitney se basa en los rangos conjuntos de ambas muestras y contrasta si una población tiende a producir valores sistemáticamente mayores que la otra. Su estadístico puede expresarse, en forma equivalente, como

$$U = R_1 - \frac{n_1(n_1 + 1)}{2},$$

donde R_1 es la suma de rangos del grupo G_1 .

La prueba de Brunner–Munzel se apoya en el parámetro de dominancia estocástica

$$p = P(X_1 > X_0) + \frac{1}{2}P(X_1 = X_0),$$

y proporciona un contraste robusto aun cuando no conviene asumir igualdad de varianzas ni formas distributivas idénticas. En este sentido, su uso complementa a Mann–Whitney cuando la heterogeneidad entre grupos puede ser más amplia.

A.8 Tamaños de efecto

El reporte informa tres medidas principales de magnitud práctica. La primera es la probabilidad de superioridad o *common language effect size*:

$$CL = P(X_1 > X_0) + \frac{1}{2}P(X_1 = X_0).$$

La segunda es la correlación biserial por rangos, que puede escribirse como

$$r_{rb} = \frac{2U}{n_1 n_0} - 1.$$

La tercera es el δ de Cliff,

$$\delta = \frac{\#(X_1 > X_0) - \#(X_1 < X_0)}{n_1 n_0}.$$

Estas medidas no sustituyen a los contrastes de hipótesis; su función es cuantificar la magnitud de la separación entre grupos en una escala interpretable, especialmente cuando el tamaño muestral hace que diferencias pequeñas resulten estadísticamente detectables.

A.9 Intervalos de confianza

Los intervalos de confianza al 95 % se reportan como rangos de compatibilidad entre los datos observados y los valores plausibles del parámetro bajo el procedimiento de estimación utilizado. En notación general,

$$IC_{95\%}(\theta) = [L, U],$$

donde L y U representan los límites inferior y superior del intervalo. En el reporte se usan para acompañar diferencias de medianas y tamaños de efecto, con el fin de complementar la evidencia puntual con una medida explícita de incertidumbre.

A.10 Heterogeneidad entre distribuciones docentes

La heterogeneidad entre patrones de calificación se resume mediante el estadístico de Kolmogorov-Smirnov:

$$D_{KS} = \sup_x |F_1(x) - F_2(x)|,$$

donde F_1 y F_2 son funciones de distribución acumulada. Este estadístico mide la mayor discrepancia vertical entre dos distribuciones acumuladas y ofrece una medida natural de distancia distributiva cuando interesa comparar forma, dispersión y localización en conjunto.

A.11 Agrupamiento mediante k-medoids

Sobre la matriz de distancias derivada de los estadísticos KS se aplica un procedimiento de agrupamiento no supervisado mediante k-medoids. A diferencia de k-means, este método representa cada grupo por una observación real del conjunto, llamada medoide. Su criterio de optimización puede escribirse como

$$\min_{M: |M|=k} \sum_{i=1}^N \min_{m \in M} d(i, m),$$

donde M es el conjunto de medoides seleccionados y $d(i, m)$ es la distancia entre la observación i y el medoide m . Esta formulación es particularmente útil cuando la matriz de disimilitud no surge de una distancia euclidiana clásica.

A.12 Criterios de selección del número de grupos

Para apoyar la elección de k se utilizan dos criterios internos. El primero es el método del codo, que examina la reducción de la disimilitud intra-grupo al aumentar el número de grupos y busca el punto a partir del cual el beneficio marginal decrece de manera marcada. El segundo es el coeficiente *silhouette*, definido para cada observación como

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

donde $a(i)$ es la disimilitud promedio de i con su propio grupo y $b(i)$ la menor disimilitud promedio con un grupo alternativo. Valores cercanos a 1 indican buena asignación, valores cercanos a 0 sugieren solapamiento entre grupos y valores negativos apuntan a una asignación inadecuada.

A.13 Alcance inferencial

Todos los procedimientos descritos en este apéndice se aplican dentro de un marco observacional. En consecuencia, los estadísticos y contrastes reportados cuantifican asociaciones, diferencias distributivas y magnitudes de efecto en los datos disponibles, pero no constituyen por sí mismos evidencia suficiente para establecer relaciones causales.